

Vježba 4 — Povratne neuronske mreže

Priprema

1. Kako funkcioniraju povratne neuronske mreže (RNN) i koje su prednosti LSTM/GRU varijanti u odnosu na “obične” RNN-ove?
2. Koja je razlika između unidirekcijskih i bidirekcijskih RNN-ova (LSTM/GRU)? U kojim slučajevima ima smisla koristiti bidirekcijski model?
3. Koje jednostavne augmentacijske tehnike se mogu primijeniti na vremenske serije poput mjerenja dobivena akcelerometrom i što im je cilj?

Opis zadatka

U ovoj vježbi potrebno je izraditi i istrenirati odgovarajući model (LSTM, GRU ili sličan sekvencijski model) za prepoznavanje (klasifikaciju) ljudskih aktivnosti na UCI HAR podatkovnom skupu. Na raspolaganju su inercijskih signali (akcelerometar i žiroskop, 9 kanala) segmentirani u prozore duljine 128 vremenskih koraka. Potrebno je najprije razmotriti način predobrade podataka (npr. skaliranje podataka, princip podjele na train/val s obzirom na osobe i sl.), definirati prikladnu arhitekturu neuronske mreže, promišljeno odabrati gubitak i vrijednosti hiperparametara. Po potrebi primijeniti tehnike augmentacije te predstaviti i analizirati rezultate na testnom skupu.

Link na podatkovni skup:

<https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>

Pre-lab pitanja

- 1) Upoznajte se s UCI HAR podatkovnim skupom. Koje senzore sadrži (tipovi signala, broj kanala)? Kakva je segmentacija u prozore (duljina prozora, preklapanje)? Koje aktivnosti postoje i kako su raspoređene po učestalosti?

9 signala sveukupno:
Kod svih 3 skupina signala su raspoređene posebne X, Y i Z vrijednosti.
Skupine signala su signali iz žiroskopa, akcelerometra te njihova fuzija.
Duljina prozora je 128.
Train data shape: (7352, 128, 9)
Test data shape: (2947, 128, 9)
30 korisnika

- 2) Ukratko opišite koju RNN arhitekturu namjeravate koristiti. Procijenite broj parametara modela.

Arhitektura je sljedeća:
Normalizacija
LSTM
Dropout
LSTM
Dropout
Povezani
Povezani

Procjena je oko 18 tisuća parametara.

- 3) Kako ćete organizirati podjelu na trening, validacijski i testni skup? Hoćete li koristiti subject-based validaciju (različite osobe u train/val/test)? Koliki postotak podataka planirate koristiti za validaciju? Zašto je takva podjela smislenija od potpuno slučajne podjele po prozorima?

Iz trening podataka, izdvajamo 20% za validaciju.

Za strategiju miješanja i odvajanja podataka na train i val, koriste se indeksi korisnika što je poboljšalo preciznost modela, ali i dalje postoji nasumičnost.

- 4) Što ćete logirati i prikazivati tijekom treninga i zašto?

Preciznost označavanja i kategorički cross entropija za loss funkciju.

Loss funkcija je potrebna za treniranje dok je preciznost više intuitivna za čovjeka.

- 5) Procijenite batch size, broj epoha, količinu podataka koje ćete koristiti te očekivano vrijeme treniranja na dostupnom hardveru (CPU/GPU).

50 epoha.

7352 uzoraka u trening podacima.

Treniranje manje od 10 minuta.

Post-lab pitanja

- 1) Ukratko opišite finalnu arhitekturu model i tehnike koje ste primijenili s ciljem efikasnijeg treniranja.

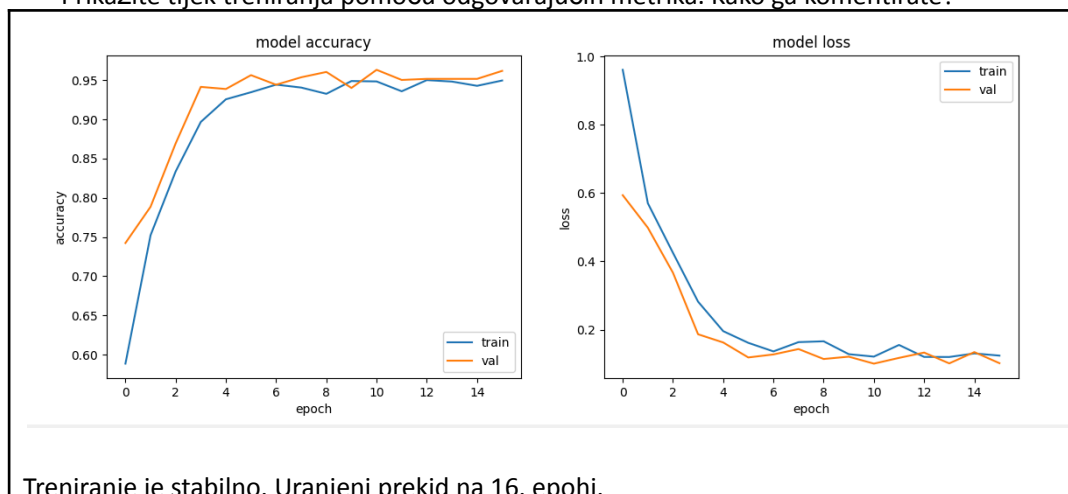
Arhitektura je sljeća:

1. Normalizacijski sloj
2. LSTM, 128 neurona
3. Dropout, 10%
4. LSTM 128
5. Dropout 10%
6. Povezani 128
7. Povezani 6

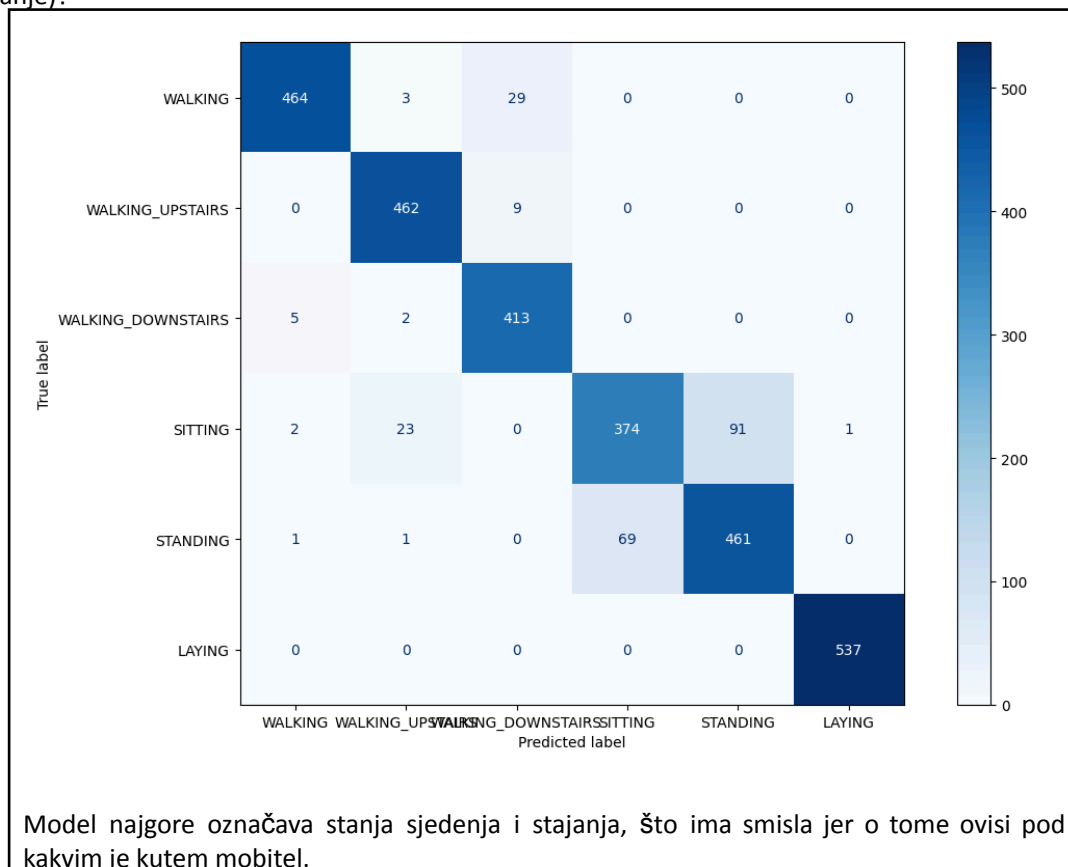
Sprema se najbolji model tijekom treniranja.

Nakon 5 gorih evaluacije na validaciji prestaje se sa treniranjem.

2) Prikažite tijek treniranja pomoću odgovarajućih metrika. Kako ga komentirate?



3) Prikažite matricu zabune te odgovarajuće metrike po klasama (na validacijskom i testnom skupu). Komentirajte dobivene rezultate. Koliko je model uspješan u prepoznavanju “dinamičkih” aktivnosti (hodanje, penjanje, spuštanje) u odnosu na “statičke” (sjedenje, stajanje, ležanje)?



4) Procijenite performanse i kompleksnost modela (koliko traje inferencija za jedan prozor (ms/uzorak) na CPU/GPU, kolika je veličina modela na disku (MB), VRAM peak).

35 ms prosječno traje inferencija za jedan prozor.
Veličina spremljenog modela jest 2.620 KB

- 5) Opišite jednu moguću praktičnu primjenu ovakvog sustava za prepoznavanje aktivnost. Koje su prednosti primjene RNN modela za takav zadatak? Koja su ograničenja i praktični izazovi?

Prepoznavanjem vrste aktivnosti se može estimirati kretanje korisnika te iz toga zaključiti koliko su napravili koraka te koliko miruju za praćenje vlastitog zdravlja.
Praktična primjena, možda ipak ne za ljude, ali slična promjena, jest detekcija preživljanja kod krava, općenito kretanje krava: hodanje, stajanje, ležanje, skakanje; te sa tim informacijama detektirati anomalije u kretanju, periode tjeranja ili mogućnosti bolesti.